

GPU가 상한을 정하지 않습니다

GPU 4장이면 추론만으로는 **200~530대**를 감당합니다. 그런데 실제 상한은 그보다 훨씬 낮습니다 — 먼저 무너지는 것은 디코딩과 네트워크이고, 진짜 비용을 정하는 것은 저장입니다. 산정의 값은 「몇 대」가 아니라 「무엇 때문에 몇 대」를 말해 주는 것입니다.

기본 구성의 답

서버 1대 = 카메라 100대
10GbE로 올리면 200~300대

안양 39대는 서버 1대로 2.5배 여유입니다. 다만 이 수는 전부 추정입니다 — 제안서·견적서·계약서에 이 수를 적으면 안 됩니다. 실측으로 바꾸는 계획이 6쪽에 있습니다.

100대

기본 구성 추정

디코딩

먼저 무너지는 관문

130 TB

100대 상시 30일

3.9배

보존 정책으로 절감

관문 다섯 · 가장 작은 것이 답입니다

흔한 실수는 GPU만 보고 대수를 정하는 것입니다. 영상 한 대가 서버에 들어와 이벤트가 되기까지 다섯 개의 관문을 지납니다. 각 관문에 저마다 상한이 있고, 전체 상한은 그중 가장 작은 것입니다. 가장 큰 관문(GPU)을 키워도 작은 관문이 그대로면 아무것도 늘지 않습니다.

§1 산정 전제

바꾸려면 이 표를 고친다

항목	값	근거 · 영향
서버 구성	GPU 4장 · 1대	대표 지시 기준 구성
영상	1080p H.264 4 Mbps	일반적인 CCTV 설정. H.265로 바꾸면 저장·네트워크가 절반이 됩니다
분석 FPS	3 fps	★ 가장 큰 레버. 화재·연기·침입은 초 단위 사건이라 30fps 추론이 필요 없습니다. 이 값이 계약 AC(F-04 5분·F-10 30초)를 만족하는지는 시험으로 확인합니다
상시 녹화	켜짐	녹화는 원본을 통과 저장하므로 디코딩·GPU 부하가 없습니다. 디스크만 씁니다
이벤트율	대당 하루 10건	재난안전 시나리오 추정 . DB·알림 부하 산정에 사용

§2 관문 다섯

#	관문	무엇이 제한하나	키우는 법
①	네트워크 수신	NIC 대역폭 ÷ 카메라당 비트레이트	10GbE로 교체 · H.265 전환
②	디코딩	분석용 프레임을 푸는 비용. GPU 하드웨어 디코더 수	선택 디코딩(필요한 프레임만) · 수집 노드 분리
③	GPU 추론	모델 처리량 ÷ 분석 FPS	분석 FPS 낮추기 · 경량 모델 · 배치 추론
④	저장	대수 제한이 아니라 용량 비용	계층 보존 · H.265 · 이벤트 구간만 장기
⑤	이벤트·DB	이벤트 생성·알림 처리량	—

⑤는 병목이 아닙니다. 실측 p95가 이벤트 13.25ms · 알림 3.42ms [실측](#)이고, 이벤트는 대당 하루 10건이면 100대에서도 초당 0.01건 수준입니다. 여유가 네 자릿수입니다. 다만 부하 없는 상태의 수이므로 부하 하에서 다시 잼니다.

관문별 상한 — 전부 추정입니다

아래 수는 전부 **추정**입니다. 계산식과 가정은 밝혀 두었으니 **가정이 틀리면 수도 틀립니다**. 실측으로 바꾸는 계획은 6쪽에 있습니다.

①

네트워크
1 GbE

175대

②

디코딩
전체 디코딩

100대 ←

③

GPU 추론
4장 · 3fps

200~533대

④

저장
비용 제약

4쪽 참조

⑤

이벤트·DB

병목 아님

기본 구성의 답

서버 1대 = 카메라 100대 (가장 작은 관문 = 디코딩)

10 GbE + 선택 디코딩으로 올리면 200~300대. GPU를 더 넣어도 늘지 않습니다 — 이미 GPU는 남습니다.

★ 안양 39대는 서버 1대로 2.5배 여유입니다.

§ ③ GPU 추론 — 분석 FPS가 대수를 세 배 가릅니다

분석 FPS	GPU당 150fps	GPU당 250fps	GPU당 400fps	비고
2 fps	300대	500대	800대	여유 크나 빠른 사건 놓칠 위험
3 fps ← 표준	200대	333대	533대	재난안전 권장 — 어차피 디코딩이 먼저 걸림
5 fps	120대	200대	320대	정밀 추적이 필요할 때

★ 이 표의 요점 — 어느 칸을 봐도 GPU 추론 상한이 디코딩(100대)보다 큼니다. 즉 지금 구성에서 GPU를 더 좋은 것으로 바꿔도 대수는 늘지 않습니다. 늘리려면 디코딩과 네트워크를 먼저 손대야 합니다 — 그게 이 산정서에서 가장 실용적인 결론입니다.

보존 정책 하나가 비용을 4배 가릅니다

상시 녹화 30일 보존

130 TB

카메라 100대 추정

백업까지 하면 260 TB

일 4.32 TB씩 쌓입니다

계층 보존

33 TB

상시 7일 + 이벤트 구간 90일

3.9배 절감 · 백업 포함 66 TB

이벤트는 오히려 3배 오래 남습니다

★ 계층 보존이 더 나은 이유는 비용만이 아닙니다. 상시 녹화는 30일 뒤 전부 사라지지만, 계층 보존은 사건이 있었던 구간을 90일 보관합니다. 재난 보고서·분쟁·감사에서 필요한 것은 사건 구간이지 아무 일 없던 새벽 3시가 아닙니다. 싸지면서 동시에 쓸모가 커집니다 — 드문 조합입니다.

§ 대수별 저장량

1080p H.264 4Mbps · 대당 0.5 MB/s

카메라	일	상시 30일	+백업	계층 보존 (7일+90일)
39대 안양 현재	1.68 TB	50.5 TB	101 TB	약 13 TB
100대 서버 1대 기준	4.32 TB	130 TB	260 TB	33 TB
150대	6.48 TB	194 TB	389 TB	약 49 TB
200대	8.64 TB	259 TB	518 TB	약 66 TB

지금 이 표가 급한 이유

지난 회신에서 「지금 장애가 나면 영상이 사라진다」고 보고드렸습니다 — 복구 예정에서 DB는 되살아났지만 영상 저장소는 백업 대상에 없었습니다. 그때 「이벤트에 묶인 것만 백업한다」고 판정했는데, 이 표가 그 판정을 뒷받칩니다: 전량 백업은 100대에 260 TB지만, 이벤트 구간만이면 수 TB입니다. 전량 백업은 비싸서 안 하게 되고, 안 하는 백업은 없는 백업입니다.

H.265로 바꾸면 위 숫자가 대략 절반이 됩니다. 다만 카메라가 H.265를 지원해야 하고, 디코딩 부하는 오히려 늘 수 있습니다 — 저장이 반으로 줄고 디코딩 관문이 조금 낮아지는 맞바꿈입니다. 현장 카메라 사양을 확인한 뒤 판단할 사안입니다.

서버 1대는 무엇을 파는 단위인가

「GPU 4장 서버 1대 = 카메라 100대」가 **추정**으로 서면, 그것은 곧 판매 단위가 됩니다. 제안·견적·증설 계획이 전부 이 단위로 쓰입니다 — 그래서 이 수를 실측으로 굳히는 것이 급합니다.

규모	카메라	서버	구성 권고 · 비고
현재 계약 안양시	39대 실측	1대	2.5배 여유. 기본 구성(1GbE)으로 충분 · 저장 계층 보존 시 약 13 TB
표준 단위	100대	1대	기본 구성의 상한 추정 · 이것이 판매 단위
확장 단위	200~300대	1대	10 GbE + 선택 디코딩 적용 시. GPU 추가 불필요
중형 지자체	300~600대	2~3대	수평 확장. 테넌트 격리는 이미 서 있어 서버를 늘리는 방식이 자연스럽습니다
광역	1,000대+	4대+	수집 노드 분리 구조로 전환 — 디코딩 전용 노드 + 추론 전용 노드

§ 대수를 늘리는 세 가지 방법 — 비용 순서

#	방법	얻는 것	비용 · 위험
1	선택 디코딩 필요한 프레임만 푼다	2~3배	개발 비용만. 장비 추가 없음 — 가장 싸고 가장 먼저 할 일
2	10 GbE 전환	①의 상한 해제	NIC·스위치 교체. ①이 걸릴 때만 의미 있음
3	수집 노드 분리	GPU 상한까지	서버 추가 + 구조 변경. 1,000대 이상에서 검토
X	GPU 추가	아무것도	이미 GPU는 납습니다. 디코딩·네트워크를 먼저 풀지 않으면 돈만 씁니다

★ 실무 결론 하나 — 지금 대수를 늘리고 싶으면 장비를 사는 것이 아니라 코드를 고치는 것이 먼저입니다. 선택 디코딩은 개발 비용만으로 2~3배를 줍니다. 장비 증설은 그것을 다 쓴 다음입니다.

이 수를 실측으로 바꾸는 법

이 산정은 「목표」이지 「약속」이 아닙니다

제안서·견적서·계약서에 이 수를 적으면 안 됩니다. 실측 없이 「100대 지원」을 쓰면 그 수가 계약이 됩니다.

이 산정의 값은 하나입니다 — 무엇을 먼저 재야 하는지, 그리고 측정이 몇 배 어긋나면 이상한지를 알려 줍니다. 실측이 추정의 1/3 이하이거나 3배 이상이면 환경이나 측정 방법을 먼저 의심합니다.

§1 GPU가 없어도 지금 짤 수 있는 것

대표 결정을 기다리지 않는다

#	짤 것	필요한 것	왜 지금인가
①	저장 대당 MB/s	지금 가능	39대 실제 쓰기량에서 바로 나옵니다. ④의 추정이 실측이 됩니다 — 가장 싸고 견적에 직결
②	디코딩·네트워크 계단	mock 스트림	추론 자리에 고정 지연 스텝을 두고 잽니다. 이름은 「추론 제외 상한」 — 이름이 술어입니다
③	이벤트·알림 부하 하 p95	부하 발생기	계약 AC(F-10 30초)를 부하 하에서 지키는지가 진짜 질문입니다
④	GPU 추론 처리량	GPU 필요	대표 결정 대기 — 이것만 못 잽니다

§2 계단 시험 — 「몇 대」가 아니라 「무엇 때문에 몇 대」

관문 하나만 남기고 나머지를 넉넉하게 만든 뒤, 그 하나를 민다
n = 10 → 20 → 40 → 60 → 80 → 100 → 120 ... 각 단계서 5분 유지

매 단계서 기록
프레임 드롭률 · 추론 지연 p95 · 이벤트 지연 p95 · 알림 지연 p95
GPU 사용률·메모리 · CPU · NIC · 디스크 쓰기 MB/s

종료 조건 = 상한의 정의. 먼저 걸리는 것이 상한이다
㉠ 프레임 드롭률 > 1% ㉡ 이벤트 지연 p95 > 1초
㉢ 계약 AC 위반 (F-10 30초 · F-04 5분) ← 가장 중요

★ ㉢이 가장 중요합니다. 부하 하에서 계약 AC를 지키는 대수가 우리가 팔 수 있는 수입니다. 드롭 없이 돌아도 알림이 30초를 넘기면 그 대수는 못 팝니다.

환경을 반드시 함께 적습니다 — GPU 모델·장수 · CPU · RAM · NIC · 디스크 · 모델명 · 입력 해상도. 환경 없는 성능 수치는 아무것도 말하지 않습니다. 그리고 그날의 커밋 해시도 적습니다 — 성능은 코드가 바뀌면 바뀌고, 어느 코드의 수인지 없으면 재현할 수 없습니다.

§3 대표계 — 결정 요청

항목	내용
필요한 것	GPU가 붙은 서버 또는 클라우드 인스턴스, 하루치. 4장이면 가장 좋고, 1장이라도 있으면 GPU당 처리량은 짤 수 있습니다(4장은 곱하기로 추정)
함께 필요	RTSP 스트림 발생기(소프트웨어로 가능) · 실제 카메라 불필요
얻는 것	「서버 1대 = 몇 대」의 실측 근거 · 제안서에 쓸 수 있는 문장 · 증설 계획의 기준
그동안	Code가 ①②③을 먼저 잽니다. GPU 없이도 상한의 하한은 나옵니다

지금 당장 하나는 시작합니다 — 저장 대당 MB/s 실측입니다. 안양 39대가 실제로 쓰고 있는 양을 재면 4쪽의 저장 표가 추정에서 실측으로 바뀝니다. 장비도 결정도 필요 없고, 저장 비용은 계약 견적에 바로 들어갑니다.